

Research
Theory and Key Technologies in Satellite Internet Networking—Article

SatFed ——一种资源高效的低轨卫星辅助异构联邦学习框架

张宇昕^{a,b}, 林政^{a,c}, 陈哲^a, 方子涵^{a,d}, 陈先浩^c, 朱文俊^{a,b}, 赵进^{a,b}, 高跃^{a,*}^a Institute of Space Internet, Fudan University, Shanghai 200438, China^b College of Computer Science and Artificial Intelligence, Fudan University, Shanghai 200438, China^c Department of Electrical and Electronic Engineering, University of Hong Kong, Hong Kong 999077, China^d Department of Computer Science, City University of Hong Kong, Hong Kong 999077, China

ARTICLE INFO

Article history:

Received 20 September 2024

Revised 17 June 2025

Accepted 14 July 2025

Available online 24 July 2025

关键词

低轨卫星网络

分布式机器学习

联邦学习

系统异构性

摘要

传统的联邦学习(FL)框架高度依赖地面网络通信,而地面通信基础设施的覆盖受限以及日益加剧的带宽拥塞显著阻碍了FL训练的收敛。幸运的是,低轨(LEO)卫星网络提供全球范围接入,为传统地面通信架构下的FL系统提供了具有前景的通信辅助方案。然而,相对受限的星地通信带宽,以及FL设备在数据、带宽和计算能力等方面的异构性,仍然对实现高效且鲁棒的卫星辅助FL系统带来了巨大挑战。为应对上述挑战,本文提出了SatFed——一种资源高效的LEO卫星辅助异构FL框架。SatFed引入基于新鲜度的模型优先级队列来优化带宽受限条件下的星地通信资源利用效率,确保FL系统中的关键模型被优先传输。此外,SatFed通过构建一个多重图,实时地捕捉设备间的异构性关系(包括数据分布、地面带宽以及算力资源)。该多重图使SatFed能够通过LEO卫星网络传输的模型更新聚合为参与FL训练的设备间的对等指导,从而提升异构环境下的本地训练效果。在真实LEO卫星网络上的大量实验表明,SatFed相较于最先进的基准方法,在性能和鲁棒性方面均表现优越。

© 2025 THE AUTHORS. Published by Elsevier LTD on behalf of Chinese Academy of Engineering and Higher Education Press Limited Company. This is an open access article under the CC BY-NC-ND license (<http://creativecommons.org/licenses/by-nc-nd/4.0/>).

1. 引言

随着无人机、智能摄像头和物联网(IoT)传感器等边缘设备的不断普及,海量的数据在网络边缘产生[1]。这些数据在机器学习(ML)的驱动下,推动了视频分析[2]、资源管理[3]和自动驾驶[4]等广泛领域中关键应用的快速发展。然而,受隐私保护需求[5]和云边带宽限制[6]的双重约束,难以将如此庞大的数据集中传输至云服务器,分布式ML训练的范式成为必然选择。

为应对上述挑战,联邦学习(FL)[7]作为一种新兴的分布式ML框架被提出,使边缘设备能够在无需共享本

地敏感数据的前提下高效地协同训练模型。FL通常采用参数服务器(PS)架构,其中,中心服务器负责聚合参与训练的边缘设备上传的模型更新。由于需要持续交换大量模型参数,FL训练效率高度依赖于稳定、高质量的云边通信。然而,现有FL系统中的参数通信完全依赖于传统地面网络。一方面,地面通信设施负载正随着用户数量和服务需求的不断增加[8–9]而日益加重;另一方面,地面网络覆盖在偏远或欠发达地区严重不足[10],最终导致参数传输延迟或拥塞[11],严重影响FL收敛。

幸运的是,低轨(LEO)卫星系统的快速发展正推动卫星宽带互联网的变革[12–13],为传统地面FL中的参数

* Corresponding author.

E-mail address: gao.yue@fudan.edu.cn (Y. Gao).

通信挑战提供了新兴解决方案。以SpaceX公司为例,其计划为Starlink巨型星座部署约42 000颗LEO卫星[14]。LEO卫星网络具备广域覆盖能力,能够支持大规模边缘设备间的点对点通信[15]。例如,当在偏远环境中参与FL训练的边缘设备(如海洋或荒野监测站)与中心服务器的地面连接不稳定时,LEO卫星链路可使其快速从多个同样参与训练的边缘节点处获取最新的知识,从而提升本地训练效果。

尽管其前景广阔,但目前LEO卫星通信辅助的FL系统仍鲜有深入研究。该系统基于卫星-地面混合通信架构,面临受限星地传输与FL客户端异构性等多重挑战。首先,LEO卫星短暂的地面接入时间(地面站可见时长小于 $5 \text{ min} \cdot \text{次}^{-1}$)与受限的对地通信带宽(如实验部分实际测量),尤其是上行链路,严重限制了FL模型参数更新的传输效率。其次,地面设备通常处于复杂且高度异构的运行环境中,表现为局部数据分布差异、地面网络条件不均以及本地计算能力参差不齐。这些系统异构性显著削弱了FL训练的性能,并构成了卫星辅助必须有效解决的主要挑战。图1展示了卫星辅助FL基本范式及其主要挑战,本文将在下一节中进行深入讨论与详细数值实验。

为应对以上挑战,本文提出了一种面向资源受限和异构环境的卫星辅助FL框架——SatFed。在SatFed架构中,每个边缘设备既训练用于本地推理的个性化模型,同时也参与全局模型的协同训练。全局模型更新通过地面网络在设备与服务器之间异步进行,而个性化模型则通过LEO

卫星网络在设备间点对点交换,实现去中心化相互协助。针对受限的星地通信连接时间与链路带宽,SatFed引入基于模型新鲜度的优先队列辅助参数传输,以确保设备能够接收到最新的对等节点模型。此外,SatFed构建了一个包含三类边的多重图,以动态刻画设备间的多样化异构关系,从而优化从卫星网络获取的对等节点模型在本地训练中的辅助效果,具体包括:①数据边,指导设备从所属数据分布相近的对等节点模型中学习;②通信边,指导设备本地训练从具备更优地面通信资源的对等节点中获益;③计算边,用于监测设备模型更新速度差异,对应动态调整本地学习率,取得全局平衡。本文的主要贡献可总结如下。

- SatFed是首个探索利用LEO卫星网络来增强传统地面FL系统的工作。通过引入模型新鲜度优先队列,SatFed有效适配卫星网络传输特性,缓解了受限带宽对于卫星辅助效果带来的影响。
- 本文提出了面向卫星辅助FL系统异构性的创新解决方案,引入多重图机制以实时监测卫星网络中的模型状态并动态刻画复杂的系统异构性。结合精心设计的本地更新策略,多重图指导显著提升了本地训练性能。
- 本研究在真实LEO卫星网络和数据集上实现了SatFed原型系统。综合实验结果表明,SatFed能够在多重异构条件下实现资源高效且鲁棒的卫星辅助FL训练。




图1. 尽管卫星网络为缓解传统地面FL系统中的通信拥塞与覆盖限制提供了潜在解决方案,但其有效性仍面临重大挑战,主要源于卫星网络有限的通信连接时间与带宽,以及FL系统的边缘设备异构性。w/表示“with”。

2. 背景与动机

本节展示了实证测量结果，以呈现卫星辅助FL所固有的挑战，从而进一步强化SatFed的设计动机。

2.1. 受限星地通信

LEO卫星沿轨道周期性运行，当处于地面设备可见覆盖范围内时启动双向数据传输，其通信吞吐量主要受限于短暂的接触时间和有限的上行带宽。例如，轨道高度为700 km的卫星约每100 min完成一次绕地轨道运行，但其与地面设备的接触窗口仅约为10 min [16]。在图2 (a)中，我们利用Starlink星座LEO卫星通信系统评估了FL中在这短暂接触期间内的参数传输效率。图2 (b)展示了基于网络测量工具Iperf [17]得出的传输速率累积分布函数(CDF)，结果显示平均下行速率约为100 Mbps，上行速率仅为12 Mbps。例如，将一个98 Mb的ResNet-50模型[18]从卫星下载至每个设备大约需要8 s，而将更新后的模型上传回卫星则需要超过1 min。因此卫星网络传输的主要瓶颈在上行链路方向。

在理想情况下，设备与卫星的每次连接都应进行大量的模型交换（见第3.2节）。然而，由于上行传输速率受限，能够成功传输的模型数量（以ResNet-50为例通常少于10个）受到严重制约。因此，FL系统在卫星传输中

优先选择关键模型，对优化卫星辅助的整体性能至关重要。

2.2. 数据异质性

卫星辅助FL的性能受到数据异质性的显著影响，因为分布在全球各地的设备会接触到来源多样的本地数据。这些设备的数据呈现非独立同分布(non-IID)特征，导致局部FL优化目标各不相同[19]，最终不同设备上传的模型更新往往偏向于各自的本地数据分布。若直接对这些更新进行参数平均以取得全局知识（如常用的FL方法FedAvg [7]），往往会导致次优性能。为更深入理解数据异质性对训练的影响，本研究在不同异质性水平下，基于ResNet-50模型使用FedAvg进行了实验，如图3 (a) [20–21]所示。实验结果清晰表明，随着数据异质性增强，模型性能显著下降。

此外，仅依赖单一全局模型还会引发设备间的公平性问题。为探究这一问题，本研究在不同异质性条件下评估了各设备利用全局模型在本地测试集上的精度，如图3 (b) [20–21]所示（其中虚线表示平均值）。结果表明，随着异质性增强，全局模型在不同设备上的性能差异显著加大，公平性明显下降。尽管已有大量研究关注数据异质性对FL的影响，但多数工作集中于PS通信框架[22]，尚未适应新兴的卫星地面混合网络架构。




图2. LEO卫星网络的上行链路构成了显著的传输瓶颈。(a) 实验设置；(b) 所得累积分布函数(CDF)展示了卫星网络的传输速率。Mbps: 兆比特每秒。




图3. 数据异质性对FL训练的影响。(a) 异质性水平；(b) 公平性。实验中将CIFAR-100数据集[20]分配给10个边缘设备，本地标签遵循Dirichlet分布； α （平衡因子）值越小，异质性越强[21]。实验参数与第4节保持一致。ID: 设备标识。

2.3. 带宽异质性

地面网络通常比卫星网络提供更高的带宽，但其性能易受多种因素影响而表现出波动性和异构性，如用户数量的动态变化、路由条件以及区域基础设施差异[23]。位于偏远地区或处于拥塞环境中的设备在参数传输中会遭遇更长延迟（即FL训练stragglers），从而减缓本地更新速度，并最终削弱整体训练性能。为更深入分析带宽异构性对FL训练的影响，本研究在不同stragglers比例下进行了实验。图4（a）表明，随着stragglers占比增加，FL的收敛速度显著减慢，准确率也大幅下降。图4（b）显示，在聚合过程中剔除过时的模型更新可在一定程度上缓解性能退化，但仍无法达到理想水平。该对比凸显了最新模型在有效提取本地知识中的重要性，而过时模型则可能对系统性能产生负面影响。

幸运的是，LEO星座中数量庞大的卫星及其广域覆盖能力，使边缘设备即便在地面网络拥塞或中断期间，仍能及时从多个对等节点处获取知识，从而缓解本地更新过时的问题。然而，在这一特殊的混合网络架构中，如何有效设计机制以解决straggler问题仍鲜有深入研究。

2.4. 算力异质性

卫星辅助FL的另一大挑战在于设备间计算能力的差

异[19,24]。部分设备由于算力不足，在相同的本地更新周期内训练不足（undertrained）。如图5（a）[25]所示，随着训练不足的设备数量增加，全局模型的测试精度显著下降。需要注意的是，如图5（b）[25]所示，由计算异构性导致的模型更新不平衡可通过提高训练不足设备的学习率加以缓解。而提升正常设备的学习率并不会带来性能提升，这表明性能改进的根本原因在于平衡更新幅度（scale）。

该发现表明，卫星网络的点对点通信模式有助于边缘设备及时感知对等节点的模型更新幅度，并据此调整本地学习率，从而保证所有设备的更新尺度相对一致。然而，在混合卫星辅助FL框架中，如何实现对对等节点更新幅度的实时、精准感知，并据此调整本地学习率以获得最优性能，仍需精细化的机制设计。

3. 框架设计

本节将详细阐述SatFed框架及其精心设计的各个组件。




图4. 带宽stragglers对FL训练的影响。(a) straggler比例；(b) straggler带来的收敛精度下降。本地更新采用异步方式聚合以形成并评估全局模型。Stragglers与服务器的通信阻塞或断连概率为90%，并每隔30 min重试一次。




图5. 不均衡训练的影响。(a) 训练不足比例；(b) 平衡效应。局部更新周期设定为30 min，假设普通设备的计算能力为4 GFlops（相当于Raspberry Pi 4 Model B的性能[25]），而训练不足的设备仅具备其1/5的计算能力。所用模型为ResNet-50，批大小为128。比例平衡（比例反平衡）通过将训练不足设备（正常设备）的本地学习率提高1.5倍来实现调整。




图6. SatFed框架系统概览。 L_{sup} 为本地监督学习损失； $L_{terrestrial}$ 为来自地面网络的全局模型指导损失； $L_{satellite}$ 为来自卫星网络的对称模型指导损失。

3.1. 基本概念与框架概述

考虑一个典型的LEO卫星辅助FL场景。每个边缘设备 $i \in [m]$ 拥有其私有数据集 $\mathcal{D}_i$ ，其数据分布为 $\mathcal{P}_i(x, y)$ ，其中， x 和 y 分别表示输入特征及对应标签， m 为参与FL训练的总边缘设备数量。设备共享一个全局模型 ω ，然而如第2.2节所述，该模型无法有效适用所有设备多样化的本地数据分布。因此，本研究为每个设备引入个性化模型 $\{v_i\}_{i \in [m]}$ ，用于本地推理。优化目标遵循基于个性化模型的先进FL方法[26]：所有设备在FedAvg框架下训练以更新全局模型 ω^* ，同时利用该模型指导各自的个性化模型更新：

$$\min_{\{v_i\}} \frac{1}{m} \sum_{i=1}^m \left\{ \mathcal{L}_i(v_i) + \frac{\mu}{2} \text{Regu}(v_i, \omega^*) \right\} \quad (1)$$

$$\text{s.t. } \omega^* \in \arg \min_{\omega} \sum_{i=1}^m \mathcal{L}_i(\omega) \quad (2)$$

式中， $\mathcal{L}_i(\omega) = \mathbb{E}_{(x,y) \sim \mathcal{D}_i} \mathcal{L}(f(\omega; x); y)$ 表示模型 ω 在数据集 $\mathcal{D}_i$ 上的经验损失， $f(\omega; x)$ 表示模型 ω 在输入 x 下的输出， $\mathbb{E}$ 表示期望算子； μ 为超参数； $\text{Regu}(\cdot, \cdot)$ 用于约束个性化模型与全局模型之间的参数距离，从而实现高效的联合训练。该机制已被广泛应用于当前先进的个性化FL方法中[26–27]。

在SatFed中，全局模型的本地更新通过地面网络异步传输至服务器进行聚合。同时，个性化模型则通过卫星网络以去中心化的方式进行点对点传输。个性化模型的训练由全局模型以及来自其他节点的个性化模型共同指导。

SatFed采用基于模型新鲜度的优先传输模式，使边缘设备能够在带宽受限的卫星网络中优先获取来自其他节点的最新模型。此外，SatFed构建了一个多重图，用于利用

卫星网络中传输的模型实时刻画多维度的异构性。该机制进一步支持从缓存的对等模型中蒸馏知识，从而保证本地更新的性能与鲁棒性。整体系统框架概览如图6所示。

3.2. 卫星网络传输模式

在由 K 颗LEO卫星组成的传输网络中，卫星 $k \in [K]$ 与设备 i 分别维护一个模型缓存 $\mathcal{C}_{sat}^k$ 与 $\mathcal{C}^i$ ，用于存储来自不同设备的个性化模型。如图6所示，当设备与某颗LEO卫星建立连接时，其会通过上行链路上传模型；卫星在经过地面设备上空时，再通过下行链路将缓存的模型传输给边缘设备。然而，正如第2.1节所述，卫星网络的复杂拓扑结构与严苛带宽限制给直接利用卫星通信进行FL传输（即缺乏针对性设计的朴素方式）带来了显著挑战。

3.2.1. 朴素传输方式的局限性

设有 L 条LEO卫星轨道，每条轨道上运行多颗卫星。对于任意轨道 $l \in [L]$ ，其覆盖的边缘设备集合记为 $S_l \subseteq [m]$ 。当任意两台边缘设备 i 与 j 被同一轨道同时覆盖时，即 $\exists l \in [L]$ ，使得 $i \in S_l$ 且 $j \in S_l$ ，本文称其为卫星网络直连（satellite-network direct），记作 $\text{SatDir}_{i,j} = 1$ ；否则，记作 $\text{SatDir}_{i,j} = 0$ 。值得注意的是，任意设备 i 可能同时被多条轨道覆盖，其覆盖轨道集合记为 S_{orb}^i 。由此可推断： $S_i^{\text{SatDir}} = \{j | j \in [m], \text{SatDir}_{i,j} = 1\} = \bigcup \{S_l | l \in S_{\text{orb}}^i\}$ 。

本文考虑两种朴素的传输模式：当设备 i 连接至卫星 k 时，其可以：①仅上传自身的个性化模型 v_i ，或②额外上传所有缓存的对等模型 $\{v_j | v_j \in \mathcal{C}^i\}$ 。在第一种方式中，轨道 l 上的卫星 k 仅能缓存 $\{v_i | i \in S_l\}$ ，导致设备 j 只能从集合 S_j^{SatDir} 内的设备获取模型，从而产生传输偏差（bias）。

如图 7 (a) 所示, 即便在平均每条 LEO 轨道覆盖多达 10 台设备且系统轨道总数高达 50 的情况下, 部分设备能够直接通信并获取对等模型的设备数, 仍不足参与 FL 训练的总节点数的一半, 造成协同知识分布的显著偏差。第二种方式通过允许卫星接收来自其他轨道的模型, 消除了上述偏差。然而, 该方式显著增加了卫星网络上行链路的传输负载, 并引入大量传输冗余。当同一模型通过多条轨道传输至另一设备时, 就会出现冗余传输, 极大消耗了卫星网络高度有限的带宽资源。如图 7 (b) 所示, 随着轨道数与覆盖范围的扩大, 这种冗余问题愈发严重, 甚至可能造成数十倍的带宽浪费。

3.2.2. 模型新鲜度优先队列

为解决传输偏差与冗余问题, SatFed 在受限的卫星网络带宽下引入了模型优先队列 (model-priority queues), 以优先传输关键模型。首先, 本文定义了卫星网络中流通的每个模型的新鲜度, 用于衡量其过时程度。具体而言, 每当设备 i 向卫星上传其个性化模型 v_i^t 时, 会在模型上打上时间戳, 记为 v_i^t , 其中, t 表示上传起始时间。在任意时刻 $\hat{t}$, 模型 v_i^t 的新鲜度定义为 $\mathcal{R}(v_i^t, \hat{t}) = 1 - e^{-\zeta(\hat{t}-t)}$, 其中, 上传时间 t 越接近当前时间 $\hat{t}$, 则模型的新鲜度越高, ζ 为调节新鲜度衰减速度的超参数。

基于模型新鲜度, 当设备 i 连接至卫星 k 时, 会构建上传与下载模型优先队列, 分别记为 $Q_{i,k}^U$ 和 $Q_{i,k}^D$ 。具体地, 在连接建立时刻 t^* , 设备 i 比较所有其他参与 FL 训练的设备 $j \in [m]$ 在本地缓存中的对等模型 $v_j^1 \in \mathcal{C}^i$, 与在卫星缓存中的对等模型 $v_j^2 \in \mathcal{C}_{\text{sat}}^k$ 的新鲜度, 即 $\mathcal{R}(v_j^1, t^*)$ 与 $\mathcal{R}(v_j^2, t^*)$: 若 $\mathcal{R}(v_i^1, t^*) > \mathcal{R}(v_i^2, t^*)$, 则将 v_j^1 添加到上传队列 $Q_{i,k}^U$; 否则, 将 v_j^2 添加到下载队列 $Q_{i,k}^D$ 。若任意缓存 $\mathcal{C}$ 中缺少来自设备 j 的模型, 则视其新鲜度为 $-\infty$, 即 $v_j^1 \in \mathcal{C}$ 。队列中的模型按照新鲜度差 $|\mathcal{R}(v_i^1, t^*) - \mathcal{R}(v_i^2, t^*)|$ 从大到小进行传输优先级排序。最终, 设备 i 按照队列中的优先顺序进行模型上传或下载, 并在接收端缓存中替换对应的过时

模型。

借助基于模型新鲜度的优先级传输队列, SatFed 有效解决了卫星网络传输中的偏差与冗余问题: ①当接收端缓存中不存在模型 v_i 或该模型已严重过时, 发送端会将其放置在队列前端优先传输, 从而最大限度缓解传输偏差; ②当两个不同卫星准备向同一接收端传输来自同一设备且上传更新时间接近的个性化模型时, 第二个模型因其新鲜度差异极小, 会在第一个模型传输完成后被置于队列末端, 只有在带宽资源明显空闲时才会传输, 从而避免冗余。

3.3. 系统异构性多重图

为了解决第 2 节中提出的复杂系统异构性问题, SatFed 构建了一个全局多重图 (multigraph), 旨在通过卫星网络中的模型交换, 实时刻画设备间的多样性异构关系, 从而辅助增强本地模型更新。本文通过边结构记录三类异构关系: ①数据边 $\mathcal{A}_{\text{sim}}$ 、②通信边 $\mathcal{A}_{\text{con}}$ 、③计算边 $\mathcal{A}_{\text{cmp}}$, 来定义多重图 $\mathcal{G}_m = ([m], \mathcal{A}_{\text{data}}, \mathcal{A}_{\text{con}}, \mathcal{A}_{\text{cmp}})$ 。具体设计如下。

3.3.1. 数据边

如第 2.2 节所述, 不同设备由于训练数据分布的差异, 表现出各自独特的本地经验风险 $\{\mathcal{L}_i\}_{i \in [m]}$ 。数据边 $\mathcal{A}_{\text{sim}}$ 的目标是帮助设备识别从卫星网络获取的哪些对等节点的个性化模型更匹配其局部优化目标。借鉴相关方法 [28], 本文通过计算训练过程中模型参数的余弦相似度来衡量本地优化目标的相似性。然而, 在模型新鲜度存在差异的卫星网络传输范式中, 简单的余弦相似度可能导致数据相似性测量不准确, 因此需要进行新鲜度校准。因此, 本文在设备 i 与 j 之间通过计算数据边 $\mathcal{A}_{\text{sim}}$ 引入置信度 $\kappa = e^{-|t^1 - t^2|}$, 其计算方式如下:

$$\mathcal{A}_{\text{sim}}(i, j) = 1 - \frac{v_i^{t^1} \cdot v_j^{t^2}}{\|v_i^{t^1}\| \|v_j^{t^2}\|} \quad (3)$$

简而言之, 当两模型的新鲜度相近 ($\kappa \rightarrow 1$) 时, 余




图 7. 卫星网络朴素传输方式的通信仿真结果。(a) 不同拓扑配置下的平均 $|\mathcal{S}_i^{\text{SatDir}}|/m$, 其中, $m=100$; (b) 设备 i 在连接卫星时上传整个缓存 $\mathcal{C}^i$ 时的系统传输冗余。冗余度定义为冗余传输次数与模型实际必要传输次数的比值。

弦相似度能够准确反映它们的本地优化目标的相似性；反之，当两模型的新鲜度差异较大（ $\kappa \rightarrow 0$ ）时，余弦相似度则无法准确反映其数据分布。该置信度 κ 用于调整相似性边的更新，见后续第3.3.4节。

3.3.2. 通信边

根据第2.3节，地面网络中的带宽滞后设备会导致模型相对过时，而通信边旨在跟踪不同设备在FL聚合中的滞后性并寻找其潜在的辅助节点，以提升SatFed的协同训练效果。具体地，本研究在给定时间窗口 W 内监测每台边缘设备 i 与负责参数聚合的中心服务器之间的通信频率 C_s^i 。相似地，本研究记录通过卫星网络从设备 j 到 i 成功传输的个性化模型的频率 C_D^{ij} 。随后，通信边计算如下：

$$\mathcal{A}_{\text{con}}(i, j) = \frac{C_s^i + \delta \times C_D^{ij}}{C_s^i} \quad (4)$$

式中， $\delta > 0$ 是平衡两项指标的权重。当在较短时间内设备 j 与服务器的参数通信次数显著多于设备 i （即 $C_s^j \gg C_s^i$ ）时， $\mathcal{A}_{\text{con}}(i, j)$ 的取值更大。这表明模型 v_i 可以更多地依赖对等节点模型 v_j 辅助，以跟上全局训练的进度，防止本地更新过时。此外， C_D^{ij} 的引入鼓励 v_i 学习来自更熟悉且更易获取的对等节点模型，从而降低整个系统收敛过程中的波动性。

3.3.3. 计算边

为减轻第2.4节中探究的不均衡训练所导致的全局模型性能下降，本文设计了计算边 $\mathcal{A}_{\text{cmp}}$ ，用于跟踪设备间的更新速度差异，从而帮助补偿训练不足的设备。本文将设备 i 的更新速度 $\mathcal{A}_i$ 定义为：其个性化模型 v_i 在一次更新前后参数的欧几里得距离，除以对应的时间间隔：

$$\mathcal{A}_i = \frac{\|v_i' - v_i\|}{t - t'} \quad (5)$$

随后，计算边 $\mathcal{A}_{\text{cmp}}$ 定义为不同设备间模型更新速度的比值：

$$\mathcal{A}_{\text{cmp}}(i, j) = \frac{\mathcal{A}_j}{\mathcal{A}_i} \quad (6)$$

基于 $\mathcal{A}_{\text{cmp}}$ ，SatFed对所有边缘设备的模型更新速度进行评估与比较，并可针对训练不足的模型调整其本地学习率，从而避免对全局模型聚合产生不利影响。

3.3.4. 多重图的更新

多重图 $\mathcal{G}_m$ 的更新由服务器与各设备共同处理，并在服务器端保持同步。在设备 i 处，当时刻 t^* 通过卫星网络下载任意对等模型 v_j' 以替换本地缓存的过时模型 v_j' 时，数据边 $\mathcal{A}_{\text{sim}}$ 采用前述置信度为权重进行更新：

$$\mathcal{A}_{\text{sim}}(i, j) = \kappa \times \frac{v_i' \cdot v_j'}{\|v_i'\| \|v_j'\|} + (1 - \kappa) \mathcal{A}_{\text{sim}}(i, j) \quad (7)$$

式中，置信度 $\kappa = e^{-|t^* - t|}$ 。此外，设备 i 会重新计算在时间窗口 W 内接收 v_j 的次数，以更新 C_D^{ij} ，并随后利用公式（4）调整 $\mathcal{A}_{\text{con}}(i, j)$ 。最后，本文计算 $\mathcal{A}_j = \frac{\|v_j' - v_j\|}{t - t'}$ ，同理计算 $\mathcal{A}_i$ ，并利用公式（6）更新 $\mathcal{A}_{\text{cmp}}(i, j)$ 。

3.4. 模型训练

本节阐述了SatFed如何利用多重图 $\mathcal{G}_m$ 引导设备从卫星网络传输的模型中提取有益知识，从而增强本地更新并提升整体训练性能。

3.4.1. 对等指导模型

在SatFed中，设备会缓存来自卫星网络的多个对等模型，但这些模型在本地更新中的有效性差异显著。为此，本文借助多重图 $\mathcal{G}_m$ ，计算权重 $\mathcal{T}(i, j)$ ，用于表示设备 i 在本地更新中对对等设备 j 的个性化模型 v_j 的依赖程度。该依赖关系遵循两个原则，与 $\mathcal{A}_{\text{sim}}$ 和 $\mathcal{A}_{\text{con}}$ 的设计目标一致：①本地优化目标越相似，设备间的相互依赖越强；②设备 j 与服务器近期通信越频繁，且其模型越频繁地被传输至设备 i ，则设备 i 对设备 j 的依赖越强。由此， $\mathcal{T}(i, j)$ 的定义如下：

$$\mathcal{T}(i, j) = \mathcal{A}_{\text{sim}}(i, j) + \alpha \times \mathcal{A}_{\text{con}}(i, j) \quad (8)$$

式中， α 为平衡因子。

利用缓存 $\mathcal{C}^i$ 中的所有对等模型 v_j' ，结合各自对应的依赖权重 $\mathcal{T}(i, j)$ ，SatFed为设备 i 在本地更新时构建一个对等指导模型 Ω_i ：

$$\Omega_i = \frac{1}{|\mathcal{C}^i|} \sum_{v_j' \in \mathcal{C}^i} e^{i-t'} \times \mathcal{T}(i, j) \times v_j' \quad (9)$$

式中， $|\mathcal{C}^i|$ 表示缓存大小，指数项用于平衡模型新鲜度以削弱缓存中过期模型的影响。

简言之， Ω_i 表示由对等模型综合而成的指导模型，它融合了在全局更新进度上更领先且与 v_i 优化目标更为一致的模型信息。

3.4.2. 全局模型更新

在SatFed训练中，全局模型 ω^* 由各设备进行本地训练，模型参数通过地面网络传输至参数服务器进行异步更新。然而，直接的本地更新会导致第2.4节中所述的训练不均衡问题，从而显著影响模型性能。为缓解这一问题，SatFed利用计算边 $\mathcal{A}_{\text{cmp}}$ ，基于实时的对等模型更新速度动态调整本地学习率。具体而言，本文以 $U^i =$

$\sum_{j \in [m]} \mathcal{L}_{\text{cmp}}(i, j)/m$ 表示设备 i 的对等设备平均更新速率。如果 $U^i \gg 1$, 则表明设备 i 在全局训练中处于滞后状态, 需要适当提高其学习率以促进全局模型聚合的一致性与稳定性。

因此, SatFed 为设备 i 构建了一个动态自适应的学习率设定:

$$\eta^i = \eta \times (1 + \gamma \times \ln \max(1, U^i)) \quad (10)$$

式中, γ 为增益系数。当设备 i 的更新速度超过全局平均水平[即 $U_i \in (0, 1)$]时, 其学习率 η^i 保持为预设的超参数 η ; 否则, η^i 会随 U_i 的增加而按对数规律提升。每轮本地更新开始时, 设备 i 从服务器获取最新的全局模型 ω^* , 并以学习率 η^i 在其数据集 $\mathcal{D}_i$ 上进行 R 轮梯度下降训练, 将得到的更新后的模型记为 ω_i^* 。随后, 该更新模型以固定权重 β 回传至服务器进行异步聚合。

3.4.3. 个性化模型更新

个性化设备模型 v_i 的训练过程由全局模型 ω^* 与对等指导模型 Ω_i 共同指导优化。需要指出的是, 在卫星网络的支持下, v_i 的本地更新不同于传统地面网络 FL 范式, 无需等待 ω^* 的送达即可持续进行。其本地优化目标可表示为

$$\min_{\{v_i\}} \frac{1}{m} \sum_{i=1}^m \left\{ \frac{\mathcal{L}_i(v_i)}{L_{\text{sup}}} + \frac{\mu}{2} \frac{\|v_i - \omega^*\|_2^2}{L_{\text{terrestrial}}} + \frac{\lambda}{2} \frac{\|v_i - \Omega_i\|_2^2}{L_{\text{satellite}}} \right\} \quad (11)$$

式中, 优化目标由三个部分组成: 本地监督学习损失 (L_{sup})、来自地面网络的全局模型指导损失 ($L_{\text{terrestrial}}$), 以及来自卫星网络的对等模型指导损失 ($L_{\text{satellite}}$)。其中, μ 和 λ 为平衡各项知识来源的正则化超参数。

SatFed 的伪代码如算法 1 所示。显然, 卫星传输使各设备能够及时接收并评估来自对等设备的模型更新状态, 辅助本地模型更新, 从而有效缓解系统异质性对 FL 训练性能的不利影响。若失去卫星通信辅助, 地面带宽或算力受限的设备将严重降低 FL 系统性能, 这一点在后续实验部分第 4.3 节中有详细讨论。值得注意的是, 尽管 SatFed 主要面向星地融合网络设计, 但其设计可为通用的混合通信架构下的 FL 系统设计提供启示。

4. 性能评估

本节通过数值实验评估所提出的 SatFed 框架的训练性能, 以及其各组成模块的独立有效性。

算法 1 SatFed

Input: η, R, β, μ , and λ

Output: $\{v_i\}_{i \in [m]}$

Initialization: $\mathcal{S}_m, \{v_i\}_{i \in [m]}, \omega^*$

Server executes:

1. **for** each device $i \in [m]$ **asynchronously do**
2. Server sends $\omega^*, \mathcal{S}_m$ to device i {terrestrial}
3. Device i updates $\mathcal{C}^i, \mathcal{S}_m$ {satellite}
4. ω_i^* LocalUpdate ($v_i, \omega^*, \mathcal{C}^i, \mathcal{S}_m, \mu, \lambda, \eta$)
5. Device i sends $\omega_i^*, \mathcal{S}_m$ back {terrestrial}
6. $\omega^* = \beta \times \omega_i^* + (1 - \beta) \times \omega^*$
7. Server updates $\mathcal{S}_m$ based on Section 3.3.4
8. **end for**

LocalUpdate ($v_i, \omega^*, \mathcal{C}^i, \mathcal{S}_m, \mu, \lambda, \eta$)

1. Build Ω_i based on Section 3.4.1
2. Compute η^i based on Section 3.4.1
3. $\omega_i^* = \omega^*$
4. **for** each local epoch $r = 1, 2, \dots, R$ **do**
5. Randomly selects a batch $\mathcal{B}_i \in \mathcal{D}_i$
6. $\omega_i^* = \omega_i^* - \eta^i \nabla \mathcal{L}_i(\omega_i^*; \mathcal{B}_i)$
7. $v_i = v_i - \eta \nabla \mathcal{L}_i(v_i; \mathcal{B}_i) - \eta \mu (v_i - \omega_i^*) - \eta \lambda (v_i - \Omega_i)$
8. **end for**
9. **return** ω_i^*

4.1. 实验设置

本文基于 Python 3.7 和 PyTorch 1.12.1 软件栈实现 SatFed, 并在 NVIDIA GeForce RTX 3090 图形处理器 (GPU) 上进行训练。实验中部署 $m = 20$ 个边缘设备, 以及分布在 $L = 10$ 个 LEO 轨道上的 $K = 20$ 颗卫星。本文选取了两个广泛采用的图像数据集: Fashion-MNIST [29] 和 CIFAR-100 [21], 通过 Dirichlet 分布生成设备间 non-IID 的标签分布 [22], 在强 non-IID 设置下将参数 α 设为 0.2, 在相对 IID 设置下将 α 设为 0.5。每个参与 FL 训练的设备本地数据集大小在 1500~2000 条之间随机分配。Fashion-MNIST 数据集采用 ResNet-18 模型, CIFAR-100 数据集对应采用 ResNet-50 模型。优化器采用 Adam [30], 学习率 η 设置为 0.001, 批量大小 (batch size) 为 128, 损失函数 $\mathcal{L}_i$ 采用交叉熵损失。

根据真实的 Starlink LEO 卫星网络参数 [16], 每个卫星轨道的运行周期为 100 min, 设置为可同时覆盖约三个边缘设备, 每个设备的平均可见时间不足 10 min。根据实测分布结果, 卫星网络的下行带宽平均为 100 Mbps, 上行带宽 10 Mbps。局部模型更新周期的上限设定为 30 min。正常参与训练的边缘设备算力为 4 GFlops (相当于 Raspberry Pi 4 Model B), 而随机一半设备的计算能力仅为其五分之

一。正常设备在理想的 200 Mbps 地面网络带宽下运行，而随机一半设备按 90% 的概率出现通信阻塞或与服务器断连，并于 30 min 后重新连接。

4.2. 总体性能

本节从训练收敛测试精度与收敛速度两个方面评估 SatFed 框架的整体性能，并进一步分析卫星网络传输状况等系统因素对 SatFed 训练过程的影响。为验证 SatFed 的优势，本文将与以下五种基线方法进行对比实验。

- **FedAvg:** 参数服务器等待所有设备完成本地更新后上传模型，再将其聚合为新的全局模型，并下发给设备开启下一轮本地训练[7]。
- **FedAsync:** 相比 FedAvg，各设备的更新模型以异步方式实时聚合至全局模型中[31]，并基于聚合后的全局模型进行下一轮本地更新。
- **Ditto:** 每个设备在训练全局模型（基于 FedAvg）时同时维护一个个性化模型，并通过 L2 正则项利用全局模型指导个性化模型更新[26]。
- **Ditto-Async:** Ditto 的异步变体，采用 FedAsync 的全局模型更新策略。
- **SatFed(-):** 仅采用 SatFed 的本地更新机制，但不引入卫星网络中基于多重图的对等指导模型。

4.2.1. SatFed 的性能优势

图 8 展示了 SatFed 与其他基线方法在 Fashion-MNIST 和 CIFAR-100 数据集上的测试精度对比结果。从图中可以

观察到，由于采取同步聚合范式，FedAvg 与 Ditto 在每轮全局模型聚合时均需等待带宽受限设备的更新参数回传，导致收敛速度明显较慢。相较之下，FedAsync 与 Ditto-Async 通过异步聚合显著加快了训练进程，但代价是模型精度波动较大，其不稳定性主要源于异步更新中使用过期模型所造成的退化。综合结果显示，SatFed 在所有方法中收敛速度最快。其优势主要得益于框架中设计的通信边，它使得带宽较差的“慢节点”能够通过卫星网络从高带宽对等节点处学习，从而缓解本地模型对整体训练进度的拖慢。此外，SatFed 的多重图中的数据边设计使设备能够选择性地与数据分布相近的节点协同，从而显著提升了最终模型精度。同时，计算边能够自适应不同设备间的模型更新速率差异，动态调整本地学习率，从而减轻不均匀训练对全局模型的负面影响。值得注意的是，SatFed(-)（即去除对等指导模型的版本）未能达到完整 SatFed 的性能水平，这一结果进一步验证了基于多重图的对等指导机制是 SatFed 优越性能的关键所在。

表 1 展示了在 Fashion-MNIST 与 CIFAR-100 数据集上的最终收敛精度与收敛速度对比结果。从表中可以明显看出，SatFed 在 CIFAR-100 的 IID 与 non-IID 设置下分别比其他方法提升了 2.35% 和 2.26%，在 Fashion-MNIST 上分别提升了 1.07% 和 1.01%，其收敛速度最高达到了传统 FedAvg 的 100 倍。SatFed 的快速收敛主要得益于其基于卫星网络的高带宽设备指导机制，有效避免了个性化模型的陈旧化问题。与 FedAvg（或 FedAsync）相比，Ditto（或




图 8. 在 IID 与 non-IID 设置下，Fashion-MNIST 与 CIFAR-100 数据集的测试精度对比结果。(a) Fashion-MNIST (IID)；(b) Fashion-MNIST (non-IID)；(c) CIFAR-100 (IID)；(d) CIFAR-100 (non-IID)。

Ditto-Async) 在 non-IID 环境下通过引入个性化模型获得了平均 8.12% 的精度提升。而与 Ditto-Async 相比, SatFed 不仅强化了数据分布相似节点间的协同训练, 还通过感知并补偿训练不均衡问题, 进一步提升了整体性能。

4.2.2. 卫星网络传输对 FL 训练的影响

图 9 展示了不同卫星网络传输模式对 SatFed 训练性能的影响。正如第 3.2.1 节所述, 若设备仅上传自身模型, 则只能接收来自卫星网络直连节点的模型, 导致对等指导模型存在知识偏差, 从而削弱其有效性。相反, 在冗余传输模式下, 设备将缓存中的所有模型上传至卫星, 虽然减少了对等指导模型知识来源的偏差, 但也显著增加了上行链路的传输负载, 易造成大量模型上传失败。在对比中可以明显看出, SatFed 采用的基于新鲜度优先的模型队列机制表现最佳。该机制在带宽受限的卫星网络中优先传输更新、更关键的模型, 从而保证了整个网络中模型的时效性与一致性, 使得对等指导模型知识始终保持最新状态, 显著提升整体 FL 训练的性能。

4.3. 消融实验

4.3.1. 数据边

图 10 展示了数据边对 CIFAR-100 数据集上 FL 训练性能的影响。从图中可以看出, 采用基于数据相似性捕捉的

自适应对等设备协同机制 ($\mathcal{A}_{\text{sim}}$) 的 SatFed 在 IID 与 non-IID 两种设置下均表现最佳。值得注意的是, 即使在没有数据边辅助的情况下, SatFed 的性能仍优于 Ditto。这表明, 即便仅使用卫星网络中设备模型的简单平均结果作为对等指导模型 Ω , 仍能带来一定的性能提升。该提升在 non-IID 场景中更为显著, 达到 1.17%, 而在 IID 场景中几乎可以忽略。这可能是因为 IID 环境下, 全局模型已具备较强的知识提取能力, 而在 non-IID 场景下其效果减弱, 需要额外的对等指导模型知识进行补充。进一步比较 SatFed 在有 $\mathcal{A}_{\text{sim}}$ 时的精度可发现, 相似性驱动模型传输机制使性能在 IID 场景下提升 2.34%, 在 non-IID 场景下提升 1.92%。通过削弱过时模型对相似性更新的干扰, $\mathcal{A}_{\text{sim}}$ 鲁棒地指导 Ω 的更新并最终显著增强了本地更新性能。

4.3.2. 通信边

图 11 展示了通信边对 CIFAR-100 数据集上的 FL 训练性能的影响。对比启用与未启用 $\mathcal{A}_{\text{con}}$ 的训练结果可以看出, 通信边的作用在训练早期最为显著。在该阶段, 各设备的模型更新方向较为一致, 带宽受限的地面设备可通过 $\mathcal{A}_{\text{con}}$ 直接从进展较快的模型中学习, 从而显著加速整体收敛过程。然而在训练后期, 由于数据异质性的影响, 不同设备的更新方向逐渐分化, 导致 $\mathcal{A}_{\text{con}}$ 的促进效果随之减弱。

表 1 SatFed 与其他基线方法的收敛测试精度 (含设备间标准差) 及收敛速度对比结果

Method	Converged accuracy (%) and speed on the Fashion-MNIST dataset		Converged accuracy (%) and speed on the CIFAR-100 dataset	
	$\alpha = 0.2$ (Non-IID)	$\alpha = 0.5$ (IID)	$\alpha = 0.2$ (Non-IID)	$\alpha = 0.5$ (IID)
FedAvg	91.75 $\pm$ 5.07	91.26 $\pm$ 4.65	50.30 $\pm$ 4.39	54.57 $\pm$ 2.91
FedAsync	92.48 $\pm$ 4.67 (5.66 $\times$)	92.07 $\pm$ 3.40 (3.39 $\times$)	48.34 $\pm$ 5.91 (12.89 $\times$)	54.20 $\pm$ 3.27 (12.18 $\times$)
Ditto	94.07 $\pm$ 4.50 (1.08 $\times$)	93.41 $\pm$ 3.87 (0.89 $\times$)	58.56 $\pm$ 5.16 (3.39 $\times$)	52.82 $\pm$ 3.17 (1.31 $\times$)
Ditto-Async	93.88 $\pm$ 4.94 (3.72 $\times$)	92.85 $\pm$ 3.47 (2.36 $\times$)	56.31 $\pm$ 7.09 (22.22 $\times$)	53.06 $\pm$ 4.32 (10.91 $\times$)
SatFed(-)	91.89 $\pm$ 7.08 (3.34 $\times$)	92.05 $\pm$ 3.77 (3.70 $\times$)	58.41 $\pm$ 8.14 (25.72 $\times$)	53.75 $\pm$ 3.92 (11.84 $\times$)
SatFed	95.08 $\pm$ 3.02 (13.82$\times$)	94.48 $\pm$ 2.23 (12.16$\times$)	60.82 $\pm$ 5.23 (100.60$\times$)	56.92 $\pm$ 2.97 (19.19$\times$)

The optimal values are in bold. Speed is the reciprocal of the ratio between the epochs needed to reach FedAvg's converged accuracy and the epochs required by FedAvg itself.




图 9. 卫星网络传输模式对训练性能的影响。(a) CIFAR-100 (IID); (b) CIFAR-100 (non-IID)。偏置传输与冗余传输的具体机制详见第 3.2.1 节; SatFed 采用基于新鲜度优先队列的调度策略。




图10. 数据边的消融实验。(a) CIFAR-100 (IID); (b) CIFAR-100 (non-IID)。为强调数据异质性对性能的影响, 所有边缘设备均处于理想的带宽与计算条件下。w/o: 表示“without”, 即未采用相应机制。




图11. 通信边的消融实验。(a) CIFAR-100 (IID); (b) CIFAR-100 (non-IID)。为了凸显地面带宽的异构性, 所有设备均在理想计算能力条件下进行训练。

4.3.3. 计算边

图12中展示了计算边对SatFed训练性能的影响。从图中可见, $\mathcal{A}_{cmp}$ 通过指导提升训练不足模型的学习率, 在IID场景下显著增强了聚合全局模型的性能。尽管在non-IID场景中的提升相对较小, 但仍有效增强了全局知识向个性化模型的注入。总体而言, 计算边在IID和non-IID环境下均能有效提升SatFed的性能, 表明其捕获本地训练进度差异, 并通过学习率调节机制有效弥合这些差异的有效性。

5. 相关工作

FL中的系统异构性涵盖数据、带宽和计算等多方面

差异, 已成为研究较为成熟的领域, 并涌现出多种解决方案。针对数据异构性问题, Li等[26]提出了个性化设备模型, 提高了系统的公平性与鲁棒性; Smith等[32]将多任务学习引入个性化FL, 将不同设备视为独立的学习任务; Ye等[28]通过度量个性化模型间的相似性, 为每个设备自适应地分配聚合权重。针对带宽异构性问题, Nguyen等[33]引入更新缓冲区机制, 用于存储设备更新结果, 以减少由模型陈旧导致的性能退化; Wang等[34]设计了基于聚类的分层FL机制, 通过结合同步与异步聚合, 实现通信资源的平衡分配。针对计算异构性导致的训练不均问题, Diao等[24]提出了定制架构的设备专属本地模型, 以适配不同的计算能力, 并据此设计相应的聚合策略。




图12. 计算边的消融实验。(a) CIFAR-100 (IID); (b) CIFAR-100 (non-IID)。为了凸显计算异构性, 所有设备均在理想的地面带宽条件下进行训练。

然而, 现有针对 FL 系统异构性的研究主要集中在地面参数服务器通信架构上, 忽视了新兴的混合通信路径(如卫星辅助地面网络)所带来的潜在优势。本文提出了一种利用 LEO 辅助通信来应对全球分布 FL 系统的异构性挑战的新方案, 该方案与上述方法正交, 可结合应用于系统中。

星地融合网络作为一种新兴且前景广阔的混合架构, 具有显著潜力, 可缓解地面网络的传输瓶颈并提升整体通信服务质量[35]。Cui 等[36]利用卫星网络辅助地面 IoT 网络, 从而降低了传输时延。Ding 等[37]则针对密集 LEO 卫星辅助的移动边缘计算场景, 设计了动态传输与计算资源优化策略。尽管 LEO 卫星在地面通信中展现出巨大潜力, 但在星地融合网络架构下开展关于 FL 系统的研究仍处于探索阶段。该问题具有高度复杂性, 需要系统性地设计模型训练、聚合与传输机制, 以适配星地融合网络架构, 同时充分考虑卫星网络拓扑、带宽限制以及 FL 训练中存在的多种异构性挑战。

6. 结论

本文提出了一种资源高效的卫星辅助 FL 框架——SatFed, 在星地融合网络架构与复杂异构环境下可显著提升训练性能与收敛速度。首先, SatFed 引入了一种基于模型新鲜度差异的优先级传输队列, 使得在传输速率受限且拓扑复杂的卫星网络中, 设备仍能够近实时且资源高效地接收对等设备的模型更新。其次, SatFed 通过多重图感知卫星网络中设备间的异构性关系, 并以此反映在卫星网络中实时传输的模型间的动态关联。最后, SatFed 利用分布式训练设备的异构性关系指导卫星网络传输的模型, 为单个独立的边缘设备构建对等指导模型, 以辅助其本地更新。大量实验结果表明, SatFed 在多个基准测试中均显著优于现有先进方法。本研究展示了在实际 LEO-星地融合网络架构中部署 SatFed 的潜力。

CRedit authorship contribution statement

Yuxin Zhang: Writing-original draft, Software, Methodology, Conceptualization. **Zheng Lin:** Writing-review & editing, Methodology. **Zhe Chen:** Writing-review & editing, Supervision, Conceptualization. **Zihan Fang:** Investigation, Data curation. **Xianhao Chen:** Supervision. **Wenjun Zhu:** Resources, Data curation. **Jin**

Zhao: Project administration, Investigation. **Yue Gao:** Supervision, Project administration.

Declaration of competing interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper.

致谢

本工作得到国家自然科学基金(62341105)资助。

References

- [1] Liu J, Ren J, Zhang Y, Yue S, Zhang Y. SESAME: a resource expansion and sharing scheme for multiple edge services providers. *IEEE/ACM Trans Netw* 2024;32 (4):3189–204.
- [2] Zhang X, Xu H, Zou L, Duan J, Wu C, Xue Y, et al. Rosevin: employing resource and rate-adaptive edge super-resolution for video streaming. In: *Proceedings of the IEEE Annual Joint Conference: INFOCOM, IEEE Computer and Communications Societies*; 2024 May 20–23; New York City, NY, USA. New York City: IEEE; 2024. p. 1–10.
- [3] Ren J, Liu J, Zhang Y, Li Z, Lyu F, Wang Z, et al. An efficient two-layer task offloading scheme for MEC system with multiple services providers. In: *Proceedings of IEEE Conference on Computer Communications*; 2022 May 2–5; online. New York City: IEEE; 2022. p. 1519–28.
- [4] Zheng T, Li A, Chen Z, Wang H, Luo J. AutoFed: heterogeneity-aware federated multimodal learning for robust autonomous driving. In: *Proceedings of the 29th Annual International Conference on Mobile Computing and Networking*; 2023 Oct 2–6; Madrid, Spain. New York City: Association for Computing Machinery (ACM); 2023. p. 1–15.
- [5] Marelli L, Testa G. Scrutinizing the EU general data protection regulation. *Science* 2018;360(6388):496–8.
- [6] Rodio A, Faticanti F, Marfoq O, Neglia G, Leonardi E. Federated learning under heterogeneous and correlated client availability. *IEEE/ACM Trans Netw* 2023;32(2):1451–60.
- [7] McMahan B, Moore E, Ramage D, Hampson S, Arcas BA. Communication efficient learning of deep networks from decentralized data. In: *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics*; 2017 Apr 20–22; Ft. Lauderdale, FL, USA. New York City: MLResearchPress; 2017. p.1273–82.
- [8] Sacco A, Flocco M, Esposito F, Marchetto G. Owl: congestion control with partially invisible networks via reinforcement learning. In: *Proceedings of IEEE Conference on Computer Communications*; 2021 May 10–13; online. New York City: IEEE; 2021. p. 1–10.
- [9] Öhlén P, Skubic B, Rostami A, Fiorani M, Monti P, Ghebreten-saé Z, et al. Data plane and control architectures for 5G transport networks. *J Lit Technol* 2016; 34(6):1501–8.
- [10] Yang D, Zhang W, Ye Q, Zhang C, Zhang N, Huang C, et al. DetFed: dynamic resource scheduling for deterministic federated learning over time-sensitive networks. *IEEE Trans Mobile Comput* 2024;23(5):5162–78.
- [11] Xu J, Kishk MA, Alouini MS. Space–air–ground–sea integrated networks: modeling and coverage analysis. *IEEE Trans Wirel Commun* 2023;22(9):6298–313.
- [12] Zhai Z, Wu Q, Yu S, Li R, Zhang F, Chen X. FedLEO: an offloading-assisted decentralized federated learning framework for low Earth orbit satellite networks. *IEEE Trans Mobile Comput* 2024;23(5):5260–79.
- [13] Zhang Y, Wu Q, Lai Z, Li H. Enabling low-latency-capable satellite–ground topology for emerging LEO satellite networks. In: *Proceedings of IEEE Conference on Computer Communications*; 2022 May 2–5; New York City, NY, USA. New York City: IEEE; 2022. p. 1329–38.

- [14] Ahmmed T, Alidadi A, Zhang Z, Chaudhry AU, Yanikomeroglu H. The digital divide in Canada and the role of LEO satellites in bridging the gap. *IEEE Comm Mag* 2022;60(6):24–30.
- [15] Lai Z, Li H, Wang Y, Wu Q, Deng Y, Liu J, et al. Achieving resilient and performance-guaranteed routing in space–terrestrial integrated networks. In: *Proceedings of IEEE Conference on Computer Communications*; 2023 May 17–20; New York City, NY, USA. New York City: IEEE; 2023. p. 1–10.
- [16] Apollonio P, Caini C, Lülfi M. DTN LEO satellite communications through ground stations and GEO relays. In: Dhaou R, Beylot AL, Montpetit MJ, Lucani D, Mucchi L, editors. *Personal satellite services*. Cham: Springer; 2013. p. 1–12.
- [17] iPerf—the ultimate speed test tool for TCP, UDP and SCTP [Internet]. Reims: iKoula; [cited 2025 Jun 18]. Available from: <https://iperf.fr/>.
- [18] He K, Zhang X, Ren S, Sun J. Deep residual learning for image recognition. In: *Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition*; 2016 Jun 27–30; VegasLas, NV, USA. New York City: IEEE; 2016. p. 70–8.
- [19] Li T, Sahu AK, Zaheer M, Sanjabi M, Talwalkar A, Smith V. Federated optimization in heterogeneous networks. In: *Proceedings of Machine Learning and Systems 2*; 2020 Mar 2–4; Austin, TX, USA. Indio: MLSys Proceedings; 2020. p. 429–50.
- [20] Chen S, Li B. Towards optimal multi-modal federated learning on non-IID data with hierarchical gradient blending. In: *Proceedings of IEEE Conference on Computer Communications*; 2022 May 2–5; London, UK. New York City: IEEE; 2022. p. 1469–78.
- [21] Tan AZ, Yu H, Cui L, Yang Q. Towards personalized federated learning. *IEEE Trans Neural Netw Learn Syst* 2022;34(12):9587–603.
- [22] Krizhevsky A, Hinton G. Learning multiple layers of features from tiny images. Toronto: University of Toronto; 2009.
- [23] Liao Y, Xu Y, Xu H, Wang L, Qian C. Adaptive configuration for heterogeneous participants in decentralized federated learning. In: *Proceedings of IEEE Conference on Computer Communications*; 2023 May 17–20; Hoboken, NJ, USA. New York City: IEEE; 2023. p. 1–10.
- [24] Diao E, Ding J, Tarokh V. HeteroFL: computation and communication efficient federated learning for heterogeneous clients. 2020. arXiv:2010.01264.
- [25] Basford PJ, Johnston SJ, Perkins CS, Garnock-Jones T, Tso FP, Pezaros D, et al. Performance analysis of single board computer clusters. *Future Gener Comput Syst* 2020;102:278–91.
- [26] Li T, Hu S, Beirami A, Smith V. Ditto: fair and robust federated learning through personalization. In: *Proceedings of the 38th International Conference on Machine Learning*; 2021 Jul 18–24; online. New York City: MLResearchPress; 2017. p.6357–68.
- [27] Dinh TC, Tran NH, Nguyen TD. Personalized federated learning with moreau envelopes. In: *Proceedings of the 34th International Conference on Neural Information Processing Systems*; 2020 Dec 6–12; Vancouver, BC, Canada. Red Hook: Curran Associates Inc.; 2020. p. 21394–405.
- [28] Ye R, Ni Z, Wu F, Chen S, Wang Y. Personalized federated learning with inferred collaboration graphs. In: *Proceedings of 40th International Conference on Machine Learning*; 2023 Jul 23–29; Honolulu, HI, USA. New York City: MLResearchPress; 2023. p. 39801–17.
- [29] Xiao H, Rasul K, Vollgraf R. Fashion-MNIST: a novel image dataset for benchmarking machine learning algorithms. 2017. arXiv:1708.07747.
- [30] Kingma DP, Ba J. Adam: a method for stochastic optimization. 2014. arXiv: 1412.6980.
- [31] Xie C, Koyejo S, Gupta I. Asynchronous federated optimization. 2019. arXiv: 1903.03934.
- [32] Smith V, Chiang CK, Sanjabi M, Talwalkar AS. Federated multi-task learning. In: *Proceedings of the 31st International Conference on Neural Information Processing Systems*; 2014 Dec 4–9; Long Beach, CA, USA. Red Hook: Curran Associates Inc.; 2014. p. 4427–37.
- [33] Nguyen J, Malik K, Zhan H, Yousefpour A, Rabbat M, Malek M, et al. Federated learning with buffered asynchronous aggregation. In: *Proceedings of The 25th International Conference on Artificial Intelligence and Statistics*; 2022 Mar 28–30; online. New York City: MLResearchPress; 2022. p.3581–607.
- [34] Wang Z, Xu H, Liu J, Huang H, Qiao C, Zhao Y. Resource-efficient federated learning with hierarchical aggregation in edge computing. In: *Proceedings of the IEEE Annual Joint Conference: INFOCOM, IEEE Computer and Communications Societies*; 2021 May 10–13; online. New York City: IEEE; 2021. p. 1–10.
- [35] Sun Y, Peng M, Zhang S, Lin G, Zhang P. Integrated satellite–terrestrial networks: architectures, key techniques, and experimental progress. *IEEE Netw* 2022;36(6):191–8.
- [36] Cui G, Duan P, Xu L, Wang W. Latency optimization for hybrid GEO–LEO satellite-assisted IoT networks. *IEEE Internet Things J* 2023;10(7): 6286–97.
- [37] Ding C, Wang JB, Cheng M, Lin M, Cheng J. Dynamic transmission and computation resource optimization for dense LEO satellite assisted mobile edge computing. *IEEE Trans Commun* 2023;71(5):3087–102.